

Wykrywanie oszustw kartami kredytowymi (Credit Card Fraud Detection)

Projekt Grupowy

Autorzy: Wojciech Sieruta, Bartosz Raczek, Wojciech Zakrzewski

7 czerwca 2026

1 Wprowadzenie i Hipoteza

Problem badawczy dotyczy detekcji anomalii w autoryzacji transakcji finansowych.

1.1 Cel i hipoteza badawcza

Hipoteza: Wykorzystanie zaawansowanych modeli uczenia maszynowego oraz odpowiednie zbalansowanie zbioru danych umożliwi skuteczne i dokładne wykrywanie fraudów, nawet w przypadku skrajnej dysproporcji między transakcjami legalnymi a oszustwami.


2 Analiza Eksploracyjna Danych (EDA) i Preprocessing

Zbiór danych zawiera zanonimizowane cechy finansowe (V1-V28) uzyskane w wyniku transformacji PCA oraz jawną kwotę transakcji (**Amount**). Klasa docelowa jest skrajnie niezbalansowana.

3 Metodologia i Modele

W celu weryfikacji hipotezy zaimplementowano cztery zróżnicowane architektury modeli:

1. **Regresja Logistyczna (Logistic Regression):** Model bazowy (baseline).
2. **Lasy Losowe (Random Forest):** Klasyfikator zespołowy oparty na drzewach decyzyjnych.
3. **XGBoost:** Algorytm gradient boosting optymalizowany przy użyciu `GridSearchCV`.
4. **Głęboka Sieć Neuronowa (TF DNN):** Wielowarstwowy model uczenia głębokiego.



Rysunek 1: Rozkład klas w zbiorze danych (transakcje legalne vs. oszustwa).


4 Wyniki i Ewaluacja

Z uwagi na specyfikę danych, głównymi metrykami oceny były ROC-AUC, PR-AUC (Average Precision) oraz F1-Score.


Tabela 1: Porównanie metryk efektywności przetestowanych modeli na zbiorze testowym.

Model	Accuracy	ROC-AUC	PR-AUC	F1-Score
Regresja Logistyczna	~0.999	0.968	0.735	0.719
Głęboka Sieć (TF DNN)	~0.999	0.979	0.710	0.787
Random Forest	~0.999	0.971	0.809	0.873
XGBoost (optymalizowany)	~0.999	0.981	0.858	0.680

Komentarz do wyników: Pozornie niższy wynik F1-Score dla modelu XGBoost (względem Random Forest) jest efektem ubocznym optymalizacji pod kątem specyfiki sektora bankowego. Model ten celowo maksymalizuje pełność (Recall), wyłapując najwięcej rzeczywistych oszustw. W biznesie koszt przepuszczenia fraudu jest wielokrotnie wyższy niż koszt weryfikacji fałszywego alarmu. Dlatego zoptymalizowany XGBoost jest bezdyskusyjnie najlepszym wyborem wdrożeniowym.



Rysunek 2: Zestawienie liczby niewykrytych oszustw (False Negatives). Model XGBoost najskuteczniej minimalizuje straty finansowe banku, przepuszczając zaledwie 11 ze wszystkich nieuczciwych transakcji w zbiorze testowym.



Rysunek 3: **Zdolność dyskryminacyjna modeli.** Lewy panel (ROC) potwierdza wysoką ogólną skuteczność separacji klas, gdzie zoptymalizowany XGBoost osiąga najwyższe pole pod krzywą (AUC=0.981). Prawy panel (Precision-Recall) obnaża jednak specyfikę skrajnie niezbalansowanych danych bankowych: spadek precyzji w modelu XGBoost jest świadomym kompromisem biznesowym. Model ten agresywniej typuje transakcje jako fraudy (maksymalizując Recall), co chroni kapitał banku kosztem większej liczby fałszywych alarmów.

5 Wnioski i Rekomendacja

Weryfikacja hipotezy: Postawiona we wstępie hipoteza została w pełni potwierdzona. Zastosowanie zaawansowanych modeli uczenia maszynowego (na czele z XGBoost) oraz odpowiednie zbalansowanie danych pozwoliło na skuteczne wykrywanie fraudów. Wyniki udowadniają, że ekstremalna dysproporcja między transakcjami legalnymi a oszustwami nie stanowi bariery nie do pokonania, jeśli proces analityczny zostanie prawidłowo zaprojektowany.

Rekomendacja wdrożeniowa: Najwyższą efektywnością biznesową wykazał się zoptymalizowany model XGBoost. Z punktu widzenia instytucji finansowej kluczowe jest zminimalizowanie liczby przepuszczonych oszustw. Jak pokazuje Rysunek 2, XGBoost przepuścił jedynie 11 ze wszystkich nieuczciwych transakcji, dystansując tym samym pozostałe algorytmy i oferując optymalny kompromis między bezpieczeństwem a znikomym odsetkiem fałszywych alarmów.