

Wykrywanie Oszustw Kredytowych

Zastosowanie Zaawansowanych Modeli AI w Sektorze Finansowym

Autorzy:

Wojciech Sieruta | Bartosz Raczko | Wojciech Zakrzewski

Hipoteza Badawcza

”

Zastosowanie zaawansowanych modeli
uczenia maszynowego oraz
balansowanie zbioru danych techniką
SMOTE umożliwi skuteczne wykrywanie
fraudów, mimo ich skrajnej dysproporcji.

”


— Główny cel weryfikacyjny projektu

Część Analityczna (EDA)

Zbiór Danych, Preprocessing i Rozkład
Zmiennych

Skrajne Niezbalansowanie Klas

- Analizowany zbiór (284 807 transakcji) posiada jedynie **492 oszustwa**.
- Transakcje fraudowe stanowią zaledwie **0.173%** całego wolumenu (stosunek 1 do 577).
- Tak duża dysproporcja sprawia, że modele bazowe będą miały tendencję do "ignorowania" oszustw w celu maksymalizacji prostego *Accuracy*.

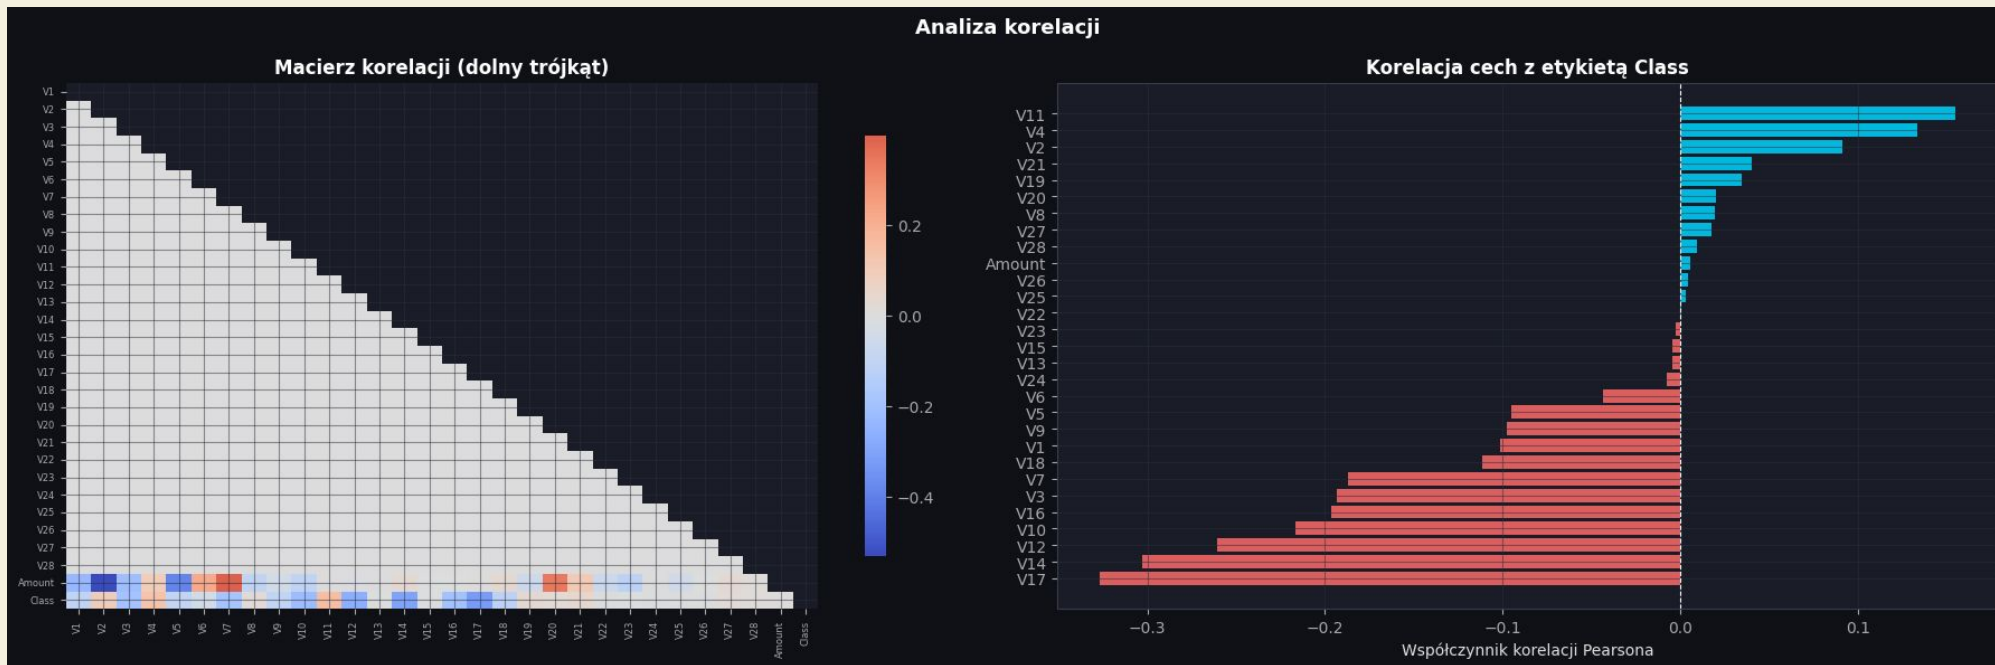


Analiza Korelacji

Związki cech z oszustwami

Przeprowadzona w raporcie macierz korelacji ujawniła, że najważniejszymi cechami zanonimizowany są V17, V14 oraz V12.

Wykazują one najsilniejszą ujemną korelację ze zmienną `Class`.



Preprocessing i SMOTE

Standaryzacja Danych

Większość kolumn (V1-V28) jest już po przekształceniach PCA. Należało jednak ujednolicić skalę oryginalnej kwoty transakcji (Amount), używając klasy StandardScaler ze Scikit-Learn.

Nadpróbkowanie SMOTE

Problem znikomej klasy rozwiązaliśmy algorytmem **SMOTE**. Wygenerował on na zbiorze treningowym dodatkowe, sztuczne wektory oszustw, wyrównując strukturę i pozwalając modelom skuteczniej analizować wejścia.

Część Implementacyjna

Modele Uczenia Maszynowego, Trening,
Optymalizacja

Kandydaci na Model



Regresja Log.

Model liniowy, bardzo szybki i interpretowalny. Stanowi u nas w projekcie punkt odniesienia (ang. *baseline*).



Sieć (TF DNN)

Czarna skrzynka (nieliniowa). Dobry eksperyment, ale trudny w biznesowej interpretacji "powodu" odrzucenia transakcji.



XGBoost

Potężny model *Ensemble* (Gradient Boosting). Główny kandydat do najlepszych wyników dzięki optymalizacji w GridSearchCV.


Metryki i Ewaluacja na zbiorze testowym

Model Uczenia Maszynowego	ROC-AUC	PR-AUC	F1-Score
Regresja Logistyczna (Baseline)	0.9682	0.7353	0.7190
Głęboka Sieć Neuronowa (TF DNN)	0.9792	0.7095	0.7870
Las Losowy (Random Forest)	0.9710	0.8090	0.8730
XGBoost (Po Optymalizacji)	0.9811	0.8583	0.6797*

* Metryka F1 w modelu XGBoost została poświęcona na rzecz zmaksymalizowania parametru **Recall**, by przepuścić jak najmniej krytycznych oszustw (kosztem fałszywych alarmów).

Wnioski i Potwierdzenie Hipotezy

- **Zwycięzca: XGBoost.** Połączenie gradient boostingu i techniki SMOTE poradziło sobie wyśmienicie z nierównością klas.
- Model uzyskał świetną dyskryminację klas (ROC-AUC ~ 0.98), co potwierdza naszą początkową hipotezę.
- Przełożyliśmy bezpieczeństwo ponad wygodę, akceptując fałszywe alarmy dla pewności blokowania przestępców.



Koniec Projektu

Dziękujemy za uwagę. Chętnie odpowiemy na pytania.

 Wojciech Sieruta | Bartosz Raczko | Wojciech Zakrzewski