

Sprawozdanie: Grupowanie K-Means na zbiorze Iris

Numer indeksu: 119111 Grupa: 2

1. Krótka analiza danych

Zbiór danych Iris składa się z 150 próbek kwiatów irysa, należących do 3 różnych gatunków: Setosa, Versicolor, Virginica (po 50 próbek dla każdego gatunku). Każda próbka opisana jest za pomocą 4 cech numerycznych:

- Długość działki kielicha (sepal length)
- Szerokość działki kielicha (sepal width)
- Długość płatków (petal length)
- Szerokość płatków (petal width)

Zbiór nie posiada żadnych brakujących danych (null values). Gatunek *Setosa* jest bardzo dobrze odseparowany liniowo od pozostałych dwóch, natomiast *Versicolor* i *Virginica* w pewnym stopniu nakładają się na siebie w przestrzeni cech, co stanowi główne wyzwanie dla algorytmów grupowania.

2. Wyniki i Metryki

Algorytm K-Means jest algorytmem uczenia nienadzorowanego (nie zna prawdziwych etykiet). Aby obliczyć metryki klasyfikacyjne, klastry wyznaczone przez K-Means (0, 1, 2) zostały najpierw zmapowane na odpowiadające im najczęstsze prawdziwe klasy (tzw. dopasowanie większościowe).

Wyniki uzyskane dla algorytmu K-Means (n_clusters=3):

- * Accuracy (Dokładność): 0.8933
- * Precision (Precyzja): 0.8953
- * Recall (Czułość): 0.8933
- * F1-score: 0.8930

Wyniki na poziomie ~89% wskazują na to, że K-Means bardzo dobrze radzi sobie z wyodrębnieniem grupy Setosa, ale popełnia pojedyncze błędy na granicy decyzyjnej między gatunkami Versicolor i Virginica z powodu ich naturalnego nakładania się na siebie.

3. Wizualizacja T-SNE

Algorytm T-SNE posłużył do redukcji wymiarowości z 4 oryginalnych cech do 2 wymiarów, co umożliwia wizualizację na płaszczyźnie. Kolory na wykresie odpowiadają klastrom przypisanym przez algorytm K-Means (po zmapowaniu).

